



"El saber de mis hijos
hará mi grandeza"

UNIVERSIDAD DE SONORA

FACULTAD INTERDISCIPLINARIA DE CIENCIAS EXACTAS Y NATURALES

DEPARTAMENTO DE FÍSICA

Programa de licenciatura en Física

Desarrollo y optimización de un modelo de redes
neuronales para la clasificación de jets de acuerdo a su
origen (quark/gluon) usando datos públicos del
experimento CMS del CERN

T E S I S

Que para obtener el título de:

Licenciado en Física

Presenta:

Oscar Ernesto Tiznado Moya

Director de tesis: Dr. Alfredo Martín Castañeda Hernández

Hermosillo, Sonora, México, 23 de abril de 2026

Jurado del Examen Profesional

Dr. Ricardo López Esparza
Universidad de Sonora, Hermosillo, México

Dr. José Feliciano Benítez Rubio
Universidad de Sonora, Hermosillo, México

Dr. Adalberto Corella Madueño
Universidad de Sonora, Hermosillo, México

Agradecimientos

Gracias por su atención.

Índice general

Agradecimientos	II
Índice general	II
1. Introducción	1
1.1. Antecedentes	1
1.2. Justificación	1
1.3. Objetivos	2
2. Marco teórico	3
2.1. Física del modelo estándar	3
2.2. Partículas elementales	3
2.3. Fuerzas fundamentales	4
2.4. Teoría cuántica de campos	5
2.5. Descubrimiento de los quarks	5
2.6. Descubrimiento de los gluones	6
2.7. Jets de hadrones	7
3. El gran colisionador de hadrones y el experimento CMS	8
3.1. El gran colisionador de hadrones	8
3.2. El experimento CMS	9
3.3. Calorímetros para detección de jets.	10
3.4. Algoritmos de reconstrucción de jets	12
3.4.1. Algoritmo anti- k_t	12
4. Conceptos generales de redes neuronales	14
4.1. Modelo de red neuronal	14
4.2. Estructura de redes neuronales.	15
4.3. Aprendizaje supervisado	17
4.4. Función de pérdida del modelo de clasificación binaria	19
4.5. Optimización por método de variación de parámetros	20
5. Análisis preliminar de muestras de datos para redes neuronales.	22
5.1. Normalización de datos	22
5.2. Estandarización de datos	23
5.3. Correlación de datos	23

6. Calificación de resultados de redes neuronales	25
6.1. Curva ROC	25
6.2. Matriz de confusión	26
7. Estrategia de análisis	27
7.1. Muestra de datos simulados.	27
7.2. Análisis de variables reconstruidas	28
7.3. Variables reconstruidas	28
7.4. Matriz de correlaciones de variables reconstruidas.	36
7.5. Entrenamiento de la red neuronal de clasificación.	36
8. Resultados	38
8.1. Modelo de red neuronal original	38
8.2. Optimización de red neuronal	39
Conclusiones	45
Perspectivas a futuro	46
A. Apéndice	47
A.1. Clasificador de probabilidad de gluones y quarks.	47
Bibliografía	48

Capítulo 1

Introducción

1.1. Antecedentes

La identificación de jets (partículas compuestas de hadrones) ha sido históricamente una tarea fundamental en la física de partículas. Las propiedades de quarks y gluones (como partículas elementales) pueden ser estudiadas de manera experimental mediante su observación como jets de partículas. Una de las primeras mediciones relevantes fue la evidencia de producción de gluones (1979) [1], los cuales fueron observados como jets, en el experimento PETRA el cual hacía uso de datos de colisión electrón-positrón del acelerador DESY (Alemania). La producción de jets y medición de sus propiedades es una combinación de predicciones teóricas y de mediciones experimentales. Los métodos tradicionales para distinguir jets provenientes de quarks o gluones tienen que ver con distribuciones de energía, momento y propiedades topológicas de la distribución de las partículas constituyentes del jet, sin embargo, en años recientes se han desarrollado modelos novedosos para optimizar el proceso de clasificación.

1.2. Justificación

En la física de altas energías, en particular en los experimentos ligados al Gran Colisionador de Hadrones (LHC, por sus siglas en inglés), la capacidad de distinguir el origen de los jets (originados por quarks o gluones) es una tarea fundamental para la separación de procesos de interés y ruido.

El proceso de formación de jets (hadronización) es complejo, ya que consiste en la recombinación de diferentes tipos de quarks y la formación de partículas que viajan en una sola dirección para finalmente depositar su energía principalmente en los calorímetros. Los métodos

tradicionales para la identificación y clasificación de jets implican varias incertidumbres tanto experimentales como teóricas.

La identificación y de jets de acorde a su origen así como su sucesivo análisis es la única manera en la que podemos verificar de forma experimental los mecanismos que se descubren teóricamente. No hay forma de observar los mecanismos que se llevan a cabo mientras sucede el proceso de hadronización, solo tenemos la capacidad de medir las cantidades físicas de los jets de harones que estos producen y esta capacidad es utilizada en diversas líneas de investigación contemporáneas como el análisis de la estructura interna de los hadrones, principalmente el protón, así como los estudios del comportamiento de las diversas interacciones actualmente teorizadas que necesitan una verificación experimental.

Recientemente se han desarrollado modelos en base a redes neuronales con el propósito de optimizar dicha clasificación, algunos de ellos hacen uso de la representación de jets como imágenes (depósitos de energía en el calorímetro) [2], mientras que otros hacen uso de las propiedades de las partículas constituyentes del jet, tales como energía, momento, posición, entre otros. El presente estudio explora la posibilidad de optimizar un modelo de clasificación de jets para incrementar la eficiencia en dicha tarea.

1.3. Objetivos

1. Estudiar muestras simuladas de procesos en la física de altas energías que contengan jets (QCD) en el contexto del experimento CMS del CERN por medio del repositorio de datos abiertos del CERN (CERN open data).
2. Entrenar un modelo en redes neuronales para la clasificación de jets conforme a su origen (quarks, gluones) y optimizar los parámetros de dicho modelo, usando los recursos computacionales del Centro de Cómputo de Alto Rendimiento de la Universidad de Sonora (ACARUS).
3. Comparar el modelo optimizado respecto a uno de referencia tomando en cuenta indicadores estadísticos como la curva ROC y matrices de confusión.

Capítulo 2

Marco teórico

2.1. Física del modelo estándar

El modelo estándar es la teoría mas aceptada de la física de partículas, a través de los años se ha demostrado robusta, siendo verificada en repetidas ocasiones por nuevos desarrollos experimentales. Esta teoría postula que nuestro universo esta fundamentalmente constituido de pequeños objetos con ciertas características en común, conocidas como partículas. Estas partículas se caracterizan por variables físicas reconocibles como la masa, la carga y el espín, las cuales constituyen todo el universo y son afectadas por cuatro fuerzas fundamentales, la fuerza nuclear fuerte y débil, gravitatoria y electromagnética, a partir de las cuales se buscan explicar todos los fenómenos físicos posibles.

2.2. Partículas elementales

Las partículas elementales representadas en la Figura 2.1 se han organizado en dos grupos principales: leptones y quarks, las cuales a su vez se han ido catalogando por generaciones. La primera generación son las más ligeras y estables, por lo cual constituyen la materia estable (quarks up y down, así como los leptones electrón y neutrino electrónico). La materia inestable y más pesada está constituida por las siguientes generaciones las cuales incluyen los quarks de segunda generación (charm y strange), leptones de segunda generación (muón y neutrino muónico) y últimamente los quarks y leptones de tercera generación que representan las partículas más pesadas e inestables (quarks top y bottom, leptones tau y neutrino tauónico). Como es de esperarse todas las generaciones inestables de partículas decaen rápidamente a las partículas de primera generación para permanecer estables *ad infinitum* (indefinidamente, sin límite).

2.3. Fuerzas fundamentales

Las cuatro fuerzas fundamentales que describen la interacción entre partículas en el modelo estándar son: fuerte, débil, gravitacional y electromagnética. Cada fuerza fundamental se describe como el resultado del intercambio de partículas: El fotón es la partícula de masa cero y carga neutra que actúa como mediadora de la interacción electromagnética; ocho gluones en total que participan en la interacción fuerte, conocidas como combinaciones lineales de colores azul, rojo y verde y sus contrapartes negativas; el tercer grupo de partículas es responsable de la interacción débil de las partículas que hace que se transforman entre sí, y consiste de tres bosones W^+ , W^- y Z . El bosón de Higgs es el responsable de otorgar masa a las otras partículas fundamentales al interactuar con el campo de Higgs. Finalmente la interacción gravitacional debe ser responsabilidad del alusivo gravitón, el cual aún no es posible observar experimentalmente pero se ha teorizado su existencia. La interacción gravitacional es tan débil a las escalas en las cuales se trabaja en el modelo estándar que ésta es completamente omitida por lo cual verdaderamente el modelo estándar solamente utiliza 3 fuerzas fundamentales hasta el momento, dejando la interacción gravitatoria para conjuntos de partículas lo suficientemente masivos para que su interacción gravitatoria sea apreciable. Todas las partículas fundamentales así como sus características más importantes han sido condensadas en el modelo estándar de las partículas elementales tal y como se muestra en la Figura 2.1.

Tres generaciones
de la materia (fermiones)

	I	II	III	
masa →	2,4 MeV/c ²	1,27 GeV/c ²	171,2 GeV/c ²	0
carga →	$\frac{2}{3}$	$\frac{2}{3}$	$\frac{2}{3}$	0
espín →	$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{2}$	1
nombre →	u up	c charm	t top	γ Foton
	4,8 MeV/c ²	104 MeV/c ²	4,2 GeV/c ²	0
	$-\frac{1}{3}$	$-\frac{1}{3}$	$-\frac{1}{3}$	0
	$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{2}$	1
Quark	d down	s strange	b bottom	g Gluon
	<2,2 eV/c ²	<0,17 MeV/c ²	<15,5 MeV/c ²	91,2 GeV/c ²
	0	0	0	0
	$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{2}$	1
	ν_e Neutrino electrónico	ν_μ Neutrino muónico	ν_τ Neutrino tauónico	Z⁰ Boson Z
	0,511 MeV/c ²	105,7 MeV/c ²	1,777 GeV/c ²	80,4 GeV/c ²
	-1	-1	-1	±1
	$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{2}$	1
Lepton	e Electrón	μ Muón	τ Tau	W[±] Boson W

Bosones de gauge

FIGURA 2.1: Modelo estándar de partículas elementales: 12 leptones, 36 quarks, 8 gluones y 5 bosones. (Imagen de uso libre obtenida de [3] con la modificación de eliminar el gravitón.)

2.4. Teoría cuántica de campos

El lenguaje que se ha establecido para describir las partículas fundamentales y sus interacciones bajo las fuerzas fundamentales es la teoría cuántica de campos [4], la cual es utilizada para describir campos cuánticos de una manera general y estructurada. En el modelo estándar se utiliza una combinación de dos teorías cuánticas de campos, una llamada la teoría electrodébil la cual engloba la interacción electromagnética y la interacción débil y la cromodinámica cuántica la cual describe la interacción fuerte de las partículas. El modelo estándar se define por sus grupos de simetría, los cuales se representan como $U(1) \times SU(2) \times SU(3)$, donde: $U(1)$ es la simetría asociada con las transformaciones de la conservación de carga eléctrica, $SU(2)$ es el grupo de simetría asociada con la fuerza nuclear débil, es decir la simetría de isospín débil. Este grupo de simetrías es utilizado para describir las interacciones mediadas por los bosones de interacción débiles ya mencionados. Últimamente el grupo de simetrías $SU(3)$ se ha asociado con la fuerza nuclear fuerte, el cual representa la simetría de cambio de color en la interacción nuclear fuerte.

2.5. Descubrimiento de los quarks

Fue alrededor de los años 60 cuando se comienza a hacer aparente que los protones y los neutrones no son partículas elementales si no que están compuestos por objetos "puntiagudos", los cuales se describieron y se les llamó partones que al ser sondeados por electrones mediante un intercambio de fotones virtuales podían ser quarks [5] y también debían poseer cargas eléctricas iguales a $1/3$ o $2/3$ la carga del electrón o del protón. En su tiempo el concepto de cargas fraccionales era revolucionario y fue fuertemente criticado por la comunidad científica. Tras una serie de experimentos fallidos para demostrar su existencia, se consideraban objetos matemáticos útiles para los modelos teóricos, pero se ponía en duda su existencia física hasta que, en los experimentos de dispersión de electrones realizados entre 1967 y 1973 por científicos del Instituto Tecnológico de Massachussets y del Centro de Acelerador Lineal Stanford en su nuevo acelerador de 20 GeV, se comprueba la existencia de los llamados quarks, alterando así el entendimiento de lo que constituye la materia hasta el momento. Este descubrimiento sería el que le otorgara también el premio Nobel de la física a Jerome Freidman, Henry Kendall y Richard Taylor en 1990.

2.6. Descubrimiento de los gluones

Después del descubrimiento de los quarks [6] como objetos físicos que constituyen a los protones y neutrones, comienzan a surgir preguntas sobre lo que esto implica, principalmente, cuales son las fuerzas que mantienen a dichos quarks ligados dentro de los bariones (partículas compuestas de tres quarks como los protones y los neutrones) y los mesones (partículas compuestas de un quark y un antiquark como los mesones π , ρ y η) y, de existir dicha fuerza, se preguntaban que partícula era encargada de llevarla y por qué es que no se observan quarks individuales. Se inició suponiendo que la fuerza que ligaba a los quarks era acarreada por bosones análogos al fotón, a los cuales se les llamó gluones. La búsqueda de los gluones comenzó naturalmente ligada a la de los quarks debido a que están fuertemente relacionados naturalmente. Los primeros indicios de la existencia de los gluones se dio en el ya mencionado experimento de dispersión de electrones, en donde el físico Chris Llewellyn-Smith descubrió que al medir la fracción del momento del protón acarreado por los quarks era aproximadamente la mitad del total, donde la otra mitad debía ser acarreado por gluones sin carga para sostener el modelo de partón de los quarks.

Al realizar una serie de experimentos buscando demostrar la existencia de los gluones, como se había realizado con los quarks hasta que se teorizó la idea de los 3 jets, en donde se postulaba que al estudiar el bremsstrahlung (radiación de frenado) en una aniquilación electrón-positrón se observaría un ensanchamiento de los jets planos y, finalmente se podrían cuantificar directamente los gluones (Figura 2.2), lo cual fue finalmente observado en 1979 gracias al colisionador electrón-positrón PETRA en Desy, Alemania, marcando el segundo bosón de Gauge descubierto después del fotón.




FIGURA 2.2: (a) Diagrama de Feynmann para la radiación de frenado del gluón. (b) Radiación de frenado de ángulo ancho en el espacio de momento del centro de masa. (c) Hadronización de la radiación de frenado de ángulo ancho. (d) Figura final del estado de 3 jets. figura obtenida de [6] página 5

2.7. Jets de hadrones

Un jet de hadrones está definido como una dispersión de partículas hadrónicas en donde la mayoría de su momento es longitudinal (paralelo al movimiento del jet) con un momento transversal (perpendicular al movimiento del jet) relativamente bajo. Estos jets son formados por colisiones de partículas, como protones, y son una herramienta fundamental para el estudio de los quarks y los gluones porque estos no pueden existir solos debido al confinamiento [7] de color, por lo cual es imposible observarlos en la naturaleza. Al formarse los jets, estos interactúan juntos y forman hadrones con carga de color neutra mediante un proceso llamado hadronización, el cual tiene como resultado los jets de hadrones, como se muestra en la Figura 2.3.

La formación de los jets es un proceso complejo y consiste de tres secciones principales en las cuales entran distintos mecanismos, el primero es la colisión, en donde inciden dos partículas compuestas, normalmente protones los cuales por conservación de momento se dispersan alrededor del área de colisión en los jets direccionales, después sigue el proceso de hadronización en donde los quarks y los gluones que salen disparados gracias a la colisión interactúan y forman hadrones, decayendo finalmente a partículas estables.

Comúnmente los jets que son estudiados en los laboratorios de física de altas energías se forman mediante colisiones de protones, en ese caso dos quarks top decaen a tres quarks separados cada uno, los cuales se reúnen para formar uno de los jets. Conocer el origen de los jets y como se deben detectar los observables en cada caso es indispensable para reconstruir el jet y extraer información de él.




FIGURA 2.3: Proceso de hadronización y eventual formación de jet de hadrones a partir de una colisión de dos protones. Imagen obtenida de [8], página 3, modificada al ser traducida a español.

Capítulo 3

El gran colisionador de hadrones y el experimento CMS

3.1. El gran colisionador de hadrones

El Gran Colisionador de Hadrones [9], construido por el Consejo Europeo para la Investigación Nuclear o CERN por sus siglas en francés (Conseil Européen pour la Recherche Nucléaire) es el acelerador de partículas más grande del mundo, construido en la frontera entre Suiza y Francia, presenta una circunferencia de 27 kilómetros y se encuentra operando a una profundidad de entre 50 y 175 metros bajo tierra, con la capacidad de acelerar partículas a una energía máxima de 14 TeV.

Como se muestra en la Figura 3.1, el gran colisionador de hadrones es solamente el último paso en un gran establecimiento, cada parte, a grandes rasgos tiene como objetivo acelerar las partículas sucesivamente hasta que llegan al LHC en donde obtienen su velocidad máxima. Las partículas comienzan en un acelerado lineal LINAC 4 en donde se aceleran iones de Hidrógeno a una energía de 160 MeV antes de ser mandados al amplificador de sincrotrón de protones (Proton Synchrotron Booster) en donde, a su vez, se aceleran las partículas a 2 GeV y las manda al sincrotrón de protones completo (PS), en donde se les continúa aumentando la aceleración hasta 26 GeV antes de entrar al super sincrotrón de protones, el segundo acelerador más poderoso del laboratorio. Además de ser el segundo más grande detrás del LHC en donde se aceleran las partículas hasta 450 GeV para ser, finalmente, introducidos al gran colisionador de partículas en donde, como ya ha sido mencionado, tiene una capacidad de energía de hasta 14 TeV.




FIGURA 3.1: Planos de los experimentos y preaceleradores en el LHC. (Figura de acceso libre distribuida por Arpad Horvath)

En su interior, el LHC es un gran laboratorio en forma de toroide donde se utiliza la energía para acelerar trillones de protones a 99.9999991 % la velocidad de la luz para después hacerlos colisionar y medir lo que sucede en su interior, para lo cual tiene sensores en su interior que almacenan todos los datos para su futuro análisis.

El colisionador de hadrones se organiza en ocho experimentos que utilizan el acelerador y son caracterizados por sus diversos detectores diseñados para detectar y analizar partículas de interés. Los dos experimentos principales y más grandes son conocidos como ATLAS, en el cual participan más de cinco mil científicos, y el CMS, el cual está conformado por 5500 científicos en 54 países. Otros experimentos menos conocidos son el experimento ALICE, LHCb, TOTEM, LHCf, MoEDAL-MAPP, finalmente, los experimentos más recientes llamados FASER y SND@LHC.

3.2. El experimento CMS

El Compact Muon Solenoid [10] (CMS) es uno de los principales experimentos presentes en el LHC, actualmente tiene aproximadamente 5500 contribuyentes activos que provienen de 54 países alrededor del mundo. Es definido como un detector multipropósito que utiliza las colisiones en el gran colisionador de hadrones para realizar sus mediciones. Los programas que realiza el CMS incluyen estudiar el modelo estándar, buscar nuevas dimensiones espaciales, agujeros negros microscópicos, así como la materia oscura, y presenta múltiples similitudes con el experimento ATLAS, pero consta de detectores diferentes para lograrlo.

El detector del CMS (Figura 3.2) está armado alrededor de un gran electroimán en forma de solenoide conformado por una espira cilíndrica de material superconductor enfriado cerca del cero absoluto con capacidad de generar 4 teslas y está confinado por un arco de acero de 14 mil toneladas. En términos generales, actúa como una cámara de alta velocidad, la cual guarda las imágenes de las colisiones de partículas en todas direcciones, alrededor de 40 millones de

veces por segundo. Debido a que la mayoría de las partículas producidas por las colisiones de partículas a altas energías son quarks y gluones altamente inestables que llevan a cabo el proceso de hadronización casi al instante, los detectores solo son capaces de detectar las variables físicas de los jets de hadrones, los cuales son partículas estables. Al identificar la mayoría de las variables de las partículas estables es posible reconstruir las interacciones de las partículas inestables que se llevaron a cabo para llegar a esas mediciones.



FIGURA 3.2: Fotografía frente al detector CMS. (Imagen obtenida de [11])

3.3. Calorímetros para detección de jets.

La forma en la que se obtienen los datos de los jets en el experimento CMS es mediante tres detectores principales [12] [13], el calorímetro hadrónico (HCAL) está formado por latón y cristales centelleantes y consiste de un barril hadrónico y dos tapas hadrónicas o HB y HE por sus respectivas siglas en inglés como se observa en la Figura 3.4 así como el calorímetro electromagnético (ECAL) el cual consiste de un barril electromagnético y dos tapas electromagnéticas, el calorímetro electromagnético está formado por 9440 bloques de cristal de plomo y de forma similar consiste un barril electromagnético y dos tapas electromagnéticas (EB y EE por sus siglas en inglés).

El HCAL [14] está formado de 75848 cristales de tungstato de plomo $PbWO_4$ los cuales están localizados dentro del imán solenoide superconductor del CMS, el barril hadrónico HB cubre el rango de jets de hadrones con una pseudorapidez (ver definición en la sección 7.3 en la ecuación 7.4) dentro del rango $|\eta| < 1.48$, mientras que las capas hadrónicas cubren $|\eta| = 3.0$

Los calorímetros dentro del CMS detectan la energía depositada por los electrones o los protones en sus cristales. Comúnmente esos depósitos de energía inciden en múltiples cristales del calorímetro por lo que son organizados usando un algoritmo de agrupamiento dinámico para agrupar la energía contribuida a cada cristal y atribuírsela a una sola partícula correctamente con los grupos que se extienden por el ángulo ϕ (ver definición en la sección 7.3) y se forman súper agrupamientos (o SC por sus siglas en inglés), con el fin de tomar en cuenta la energía perdida por el bremsstrahlung o energía de la radiación de frenado de los electrones. Finalmente,




FIGURA 3.3: Esquema del cuarto del calorímetro hadrónico donde se señalan los componentes principales como el barril hadrónico HB, tapa hadrónica HE, exterior hadrónico HO y el frente hadrónico HF. (Imagen obtenida de [12] pagina 3 con modificaciones para enfatizar las secciones del calorímetro hadrónico y ser traducido al español).




FIGURA 3.4: Esquema del cuarto del detector mostrando el acomodo del calorímetro hadrónico así como el calorímetro electromagnético donde se señalan los componentes principales como el barril hadrónico HB, tapa hadrónica HE, barril electromagnético EB y tapas electromagnéticas EE (Imagen obtenida de [13] página 362, con la modificación de ser traducido al español).

la energía completa es calculada con la siguiente formula:

$$E_{e,\gamma} = F_{e,\gamma} X [E_{ES} + G(\eta) X \sum_i C_i X S_i(t) x A_i(t)] \quad (3.1)$$

Para todos los cristales i del súper grupo, A_i es la amplitud de canal singular reconstruida, $S_i(t)$ es la corrección dependiente del tiempo de la respuesta del cristal, C_i es la constante de intercalibración del canal, $G(\eta)$ es la escala de conversión absoluta de salida luminosa ADC a energía absoluta GeV, E_{ES} es la energía depositada antes de la lluvia de hadrones y $F_{e,\gamma}$ es la corrección de los súper agrupamientos debido al bremsstrahlung (diferente para fotones y electrones).

El primer paso que se realiza al detectar los eventos dentro del CMS es la amplificación y digitalización de la energía depositada en los cristales y sus fotodetectores. Se almacenan los datos de 10 muestras consecutivas con un tiempo entre muestras de 25 ns, con lo cual se realiza la

extracción de la amplitud del evento así como la reconstrucción del pulso. Una vez digitalizadas, estas pueden ser organizadas en grupos separados por 25 ns y los que no están separados por 25 ns se llaman eventos fuera de tiempo (también conocidos como OOT, por sus siglas en inglés). El algoritmo de reconstrucción busca minimizar lo más posible las contribuciones OOT para la disminución del ruido en la muestra al ser analizada.

Una vez obtenida las muestras digitalizadas y amplificadas se realizan las correcciones como se observa en la formula (3.1) para disminuir los errores y aumentar la certidumbre de las muestras medidas y sus respectivos datos almacenados.

3.4. Algoritmos de reconstrucción de jets

Fundamentalmente todos los algoritmos de agrupamiento secuencial [15] siguen los mismos pasos para identificar los jets formados de partículas. Se comienza definiendo las variables como sigue: la distancia entre dos partículas $d_{i,j} = \min(p_{ti}^a, p_{tj}^a) \times \frac{R_{ij}^2}{R}$ donde a es el exponente que define a los diferentes tipos de algoritmos de esta categoría, $R_{i,j} = (\eta_i - \eta_j)^2 + (\phi_i - \phi_j)^2$ es la distancia en el espacio de momentos entre dos partículas y R es el parámetro de radio, el cual determina el tamaño final del jet, la segunda variable de distancia definida es $d_{iB} = p_{ti}^a$ que se define como la distancia en el espacio de momentos entre el eje del haz y la partícula detectada. Con esas variables definidas, los algoritmos de agrupamiento secuencial [16] siguen los siguientes pasos:

1. Encontrar la distancia mínima d_{ij} en toda la muestra de datos $\{d_{ij}, d_{iB}\}$.
2. Si d_{ij} es la distancia mínima se combinan las partículas i, j en una sola partícula (ij) con suma de cuadrivectores y las partículas individuales i, j se eliminan de la muestra de datos.
3. Si d_{iB} es la distancia mínima la partícula i es etiquetada como el jet completo y la partícula individual es eliminada de la muestra de datos.
4. Se repite al algoritmo hasta que todas las partículas sean parte de un jet o, si se define un número específico desde el principio, al alcanzar ese número de jets el resto de las partículas que no forman parte de un jet son excluidas de la base de datos.

3.4.1. Algoritmo anti- k_t

El algoritmo anti- k_t [17] se comporta como un algoritmo de cono idealizado, en donde se supone que todas las partículas de un jet aparecerán en regiones cónicas en el espacio de momentos $(\eta - \phi)$ donde η es la pseudorapidez (sección 7.3, ecuación 7.4) y ϕ es el ángulo azimutal (ver sección 7.3), además de ser de la familia de los algoritmos de cono, el algoritmo anti- k_t es

catalogado como un algoritmo de agrupamiento secuencial, en donde se asume que las partículas que constituyen un solo jet presentan poca diferencia en su momento transversal (ver definición en la sección 7.3) y resulta en jets con diferentes áreas en el espacio de momentos.

En específico el algoritmo anti- k_t es el que se presenta con un valor del exponente en la variable de distancia de $a = -2$ obteniendo así las siguientes variables de distancia:

$$d_{i,j} = \min\left(\frac{1}{p_{ti}^2}, \frac{1}{p_{tj}^2}\right) \times \frac{R_{ij}^2}{R} \quad (3.2)$$

$$d_{iB} = \frac{1}{p_{ti}^2} \quad (3.3)$$

Donde se observa que la ecuación (3.2) está dominada por valores de p_t altos, por lo que tiende a favorecer a las partículas que presentan valores altos de momento transversal. Este algoritmo es el que tiene más capacidades de identificar y agrupar jets correctamente, pero no tiene capacidad de analizar la subestructura de los jets.




FIGURA 3.5: Representación de colisión de hadrones. (Imagen obtenida de [15] pagina 2 con la modificación de ser traducida al español).

Capítulo 4

Conceptos generales de redes neuronales

4.1. Modelo de red neuronal

Las redes neuronales son un modelo de inteligencia artificial que busca imitar el funcionamiento del cerebro animal utilizando unidades simples llamadas neuronas, los cuales individualmente siguen un modelo de regresión lineal, el cual esta formado por cuatro elementos en total: la entrada, el peso, el sesgo y la salida (o como son conocidas comúnmente por sus nombres en inglés: input, weight, bias y output respectivamente), los cuales tienen la forma común de la regresión lineal.

$$wx + b = y \quad (4.1)$$

En donde w es el peso, x es la entrada, b es el sesgo, y es la salida, estos pueden ser combinados con múltiples neuronas en una organización llamada capa, cada neurona de diferente peso y entrada (w_i, x_i) pero toda la capa utiliza el mismo sesgo b . La organización de capas es sucesiva como se muestra en la Figura 4.1, En donde la capa de entrada representa los valores iniciales, como los obtenidos en la muestra de datos. Como ya ha sido mencionado, cada neurona tiene una entrada y un peso pero cada capa completa tiene un sesgo por lo cual la forma del modelo de regresión lineal para cada capa es como sigue:

$$y = \sum_{i=1}^n w_i x_i + b \quad (4.2)$$

El resultado de la capa de entrada se convierte en el valor de entrada de la primera capa escondida, cuya salida se convierte en la entrada de la siguiente capa escondida y así sucesivamente hasta la última capa escondida, la cual provee el valor de entrada a la capa de salida como se

muestra en la Figura 4.2, la cual, como su nombre lo dice, calcula el valor final de salida para esa iteración o epoch como es conocida en inglés.




FIGURA 4.1: Figura donde se muestra la arquitectura general de los modelos de redes neuronales.

4.2. Estructura de redes neuronales.

Las activaciones de las capas más comunes en los modelos de redes neuronales son: ReLu (lineal rectificado, por su abreviación en inglés), dropout (Capa de abandono) y sigmoide. Las capas que consisten en activaciones ReLu se comportan como una activación lineal cuando




FIGURA 4.2: Figura simplificada en donde se muestra el algoritmo para una iteración de aprendizaje de una red neuronal de 5 unidades o neuronas. (Imagen de acceso publico distribuida por Alejandro Cartas).

la entrada es $x > 0$ con la diferencia de que el resultado es 0 cuando $x \leq 0$, como se observa en la Figura 4.3. Esta activación es una de las más utilizadas en modelos de red neuronales debi-




FIGURA 4.3: Gráfica activación ReLu.

do a su simplicidad ya que evita cálculos complicados al momento de entrenamiento, salvando recursos computacionales. Su capacidad de apagarse es muy importante ya que al comenzar el entrenamiento solamente las neuronas requeridas tendrán una activación y las que no, se mantendrán con valor de salida igual a cero, lo cual previene el sobreentrenamiento así como ayudar a reducir los gastos de recursos.

La activación dropout es una capa que indica a un porcentaje de activaciones de la capa que le sigue a desactivarse temporalmente durante el entrenamiento, por ejemplo, después de una capa dropout con parámetro de 0.2 viene una capa completamente conectada que consiste de 10 activaciones ReLu, por cada iteración en el entrenamiento se apagan 2 neuronas aleatorias, lo cual evita el sobreentrenamiento y aumentar la capacidad de generalización de un modelo (ver Figura 4.4).

La activación sigmoide es utilizada comúnmente para obtener una probabilidad y su ecuación es.

$$f(x) = \frac{1}{1 + e^{-x}} \quad (4.3)$$

que tiene la gráfica presentada en la Figura 4.5

Como se observa, dicha función obtiene una entrada x para la cual obtiene un resultado $f(x) \in (0, 1)$, el cual es comúnmente tomado como la probabilidad de una variable binaria que se busca predecir.




FIGURA 4.4: Ejemplo de capa dropout donde 20 % de las casillas son desactivadas de una capa a la otra en cada iteración.




FIGURA 4.5: Gráfica función sigmoide.

4.3. Aprendizaje supervisado

En el aprendizaje supervisado se utilizan datos en los cuales se conoce el resultado así como sus variables para entrenar el modelo. Comúnmente se inicia separando la muestra de datos completa en dos subconjuntos conocidos como los datos de entrenamiento y los datos de prueba. El porcentaje de los datos que se considera para cada uno de los subconjuntos varía con cada muestra de datos, un valor común es 80 % en el subconjunto de entrenamiento y 20 % en el subconjunto de prueba.

En la Figura 4.6 se muestra una iteración de un modelo de aprendizaje supervisado con la adición de la actualización de pesos en función del error obtenido en una iteración. El algoritmo

comienza con los datos de entrenamiento, donde para la primera iteración se utilizan pesos aleatorios, después se compara el resultado obtenido con el valor real y los pesos del modelo se ajustan acorde a la diferencia entre el valor obtenido por la función de activación y el valor real. Si el modelo predice un valor muy diferente al correcto se produce un cambio mayor y si la diferencia es menor se produce un cambio menor.




FIGURA 4.6: Algoritmo de aprendizaje supervisado con la adición de propagación hacia atrás. (Imagen de acceso público distribuida por Alejandro Cartas con la modificación de la actualización de pesos).

Una vez que se ajusta el modelo, se ensaya con los datos de prueba para medir la capacidad del modelo para generalizar sus predicciones sobre una muestra de datos en la cual se pueden conocer las mismas variables con las que el modelo fue entrenado pero donde no se conoce el resultado. Una vez que se obtiene la capacidad de generalización del modelo actual se utiliza para modificar sucesivamente el modelo utilizando una función error, la cual se busca minimizar para llegar a un modelo con mayor capacidad de generalizar sus predicciones.

En los modelos de clasificación se busca identificar entre dos o más categorías posibles, entrenando el modelo para predecir qué categoría es más probable que pertenezca una muestra desconocida.

La manera de obtener una probabilidad para realizar una predicción se realiza con la última activación del modelo siendo una función sigmoide, el cual obtiene un valor de entrada y el valor de salida es la probabilidad de que una variable binaria cualquiera tenga valor 1. Como el valor de salida de la función sigmoide es un continuo entre 0 y 1 se debe acotar el punto en donde se decide cortar para tomar una probabilidad como indicativa de que el valor es verdadero. El

punto de corte se ajusta a las necesidades de cada modelo, en algunos modelos es suficiente con que exista más del 50 % de probabilidad para considerarse como verdadero mientras que en algunos otros se requiere mas certitud, comúnmente entre 70 % y 80 %. Aumentar el valor de corte disminuye la cantidad de falsos positivos pero a su vez aumenta la cantidad de falsos negativos.

4.4. Función de pérdida del modelo de clasificación binaria

Para evaluar la capacidad de clasificación de un modelo para que sea posible el algoritmo de aprendizaje de propagación hacia atrás, se necesita establecer una función para evaluar la pérdida que se obtiene cuando se compara la salida del modelo con el valor real que se busca identificar. Como ya se ha mencionado, la función de salida más común para la clasificación es la del sigmoide de la Figura 4.5, la cual en teoría tiene un valor de entrada de $-\infty$ a ∞ y un valor de salida entre 0 y 1. Posteriormente, se busca una función que se separe en dos casos: si el valor real denotado t es 0, se busca que la función error tenga un valor alto. Si el valor de salida del modelo es lejano a cero, se busca que esta misma función error tenga un valor bajo si el valor de salida es cercano a 0. De forma similar si t es 1 se busca un valor de pérdida alto cuando la salida del modelo sea cercana a 0 y un valor de pérdida bajo cuando la salida del modelo sea cercana a 1. Con lo anterior se define la función de pérdida para la clasificación binaria, conocida comúnmente como pérdida de entropía cruzada binaria que tiene la siguiente formula:

$$E = -t \log(f(x)) - (1 - t) \log(1 - f(x)) \quad (4.4)$$

Donde $f(x)$ es el valor de salida de la función sigmoide (un número real entre 0 y 1). Al separar la función error para ambos casos, cuando $t = 0$ y $t = 1$, comenzando cuando el valor real es $t = 0$ se obtiene la primera función error.



$$E = -\log(1 - f(x)) \quad (4.5)$$

En la Figura 4.7 se muestra la gráfica de esta función, donde se observa que al evaluar la gráfica en el valor correcto $f(x) = 0$ se obtiene un valor de la función error de 0. Este valor va aumentando a medida que el valor se va acercando a 1, indicando que existe un error mayor entre la predicción y el valor real.

De manera similar para el valor de $t = 1$ la función de error al ser evaluada resulta en

$$E = -\log(f(x)) \quad (4.6)$$

como se muestra en la Figura 4.8, en donde al evaluar la función cercana a uno es decir el valor

FIGURA 4.7: Gráfica de la función pérdida cuando $t = 0$.FIGURA 4.8: Gráfica de la función pérdida cuando $t = 1$.

real esperado, la función error tiende a cero, mientras que al acercarse a cero la función error tiende a infinito.

4.5. Optimización por método de variación de parámetros

Se utiliza el método de variación de parámetros en las redes neuronales para encontrar el modelo con la menor pérdida dada una muestra de datos. Las variaciones se realizan en la

mayor cantidad posible de características del modelo, las cuales pueden incluir: número de capas y número de activaciones por capa, tipos de capa, punto de corte para la clasificación y tasa de aprendizaje.

Las dos formas principales que se utilizan para la variación de parámetro son:

1. Búsqueda aleatoria. Este método consiste en variar los parámetros de forma aleatoria y se comparan sus resultados entre si.
2. Búsqueda en red. Este método funciona al variar los parámetros de manera organizada en red en donde se van cambiando los parámetros sobre una tabla predeterminada.

En la Figura 4.9 se presenta una representación visual de la optimización mediante ambos métodos.




FIGURA 4.9: Comparación entre método de variación de parámetros para optimización aleatoria y en red.

Capítulo 5

Análisis preliminar de muestras de datos para redes neuronales.

5.1. Normalización de datos

Se realiza una normalización en la muestra de datos para tomar en cuenta cualquier sesgo por magnitud (en donde el modelo de red neuronal naturalmente tiende a darle mas influencia a las variables de magnitud mayor) que se presente. La normalización ayuda también al proceso de convergencia del modelo haciéndolo más eficiente. En este trabajo, para realizar la normalización se toman todas las variables y se dividen entre el el área bajo la curva de su histograma para así normalizar las muestras de jets provenientes de quarks y de gluones y eliminar el sesgo por magnitudes.

Después de la normalización se grafican ambos histogramas en una misma gráfica como se muestra en la figura 5.1 para así comparar visualmente sus diferencias y poder detectar cuales son mejores para identificar el origen de los jets. Mientras que la mayoría de las variables presentan similitudes entre los jets generados por gluones y los jets generados por quarks, existen algunas variables que son diferentes para ambos tipos de jet.




FIGURA 5.1: Normalización de histogramas donde se divide entre la integral de cada grafica para obtener dos histogramas cuyas áreas bajo la curva son igual a 1

5.2. Estandarización de datos

La estandarización de los datos, también conocida como normalización de factor z es un procedimiento que se lleva a cabo sobre una base de datos para asegurarse de que la media sea igual a cero y la desviación estándar sea igual a 1, la estandarización de datos es importante ya que permite que las redes neuronales para evitar el sesgo dimensional que se obtiene con datos cuya distancia varía mucho antes de ser estandarizada como se muestra en la figura 5.2.

$$x_s = \frac{x - m\mu}{\sigma} \quad (5.1)$$

donde μ es la media de la base de datos y σ es la desviación estándar de los datos.




FIGURA 5.2: Estandarización de una variable mediante normalización de factor z

5.3. Correlación de datos

La correlación entre dos variables se mide con un coeficiente obtenido al comparar ambas bases de datos para analizar si los valores de una de las variables es indicadora de los valores de otra variable, el coeficiente de correlación ρ es obtenido con la siguiente forma:

$$\rho_{xy} = \frac{Cov(x, y)}{\sigma_x \sigma_y} \quad (5.2)$$

donde $Cov(x, y)$ es conocida como la covarianza de las variables y se calcula de la siguiente forma:

$$Cov(x, y) = \sum \frac{(x_i - \mu)(y_j - v)}{n} \quad (5.3)$$

En donde x_i , y_i son todos los valores de las variables x , y , respectivamente, y μ , v son los promedios de las variables x , y , respectivamente. En la Figura 5.3, se observa cómo se comportan las gráficas de dos variables que presentan algún tipo de correlación entre ellas así como el caso en donde no la presentan.




FIGURA 5.3: Gráficas en donde se observan las gráficas de dos variables con correlación positiva, negativa y nula

Capítulo 6

Calificación de resultados de redes neuronales

6.1. Curva ROC

La curva característica operativa del receptor (o ROC por sus siglas en inglés) es una gráfica utilizada para medir la capacidad de un modelo de clasificación. Esta se obtiene graficando la tasa de falsos positivos contra la tasa de verdaderos positivos, haciendo variar el punto de corte para tomar la decisión de cuando un valor es positivo y cuando es falso. En la Figura 6.1 se presenta una curva ROC estándar así como los dos casos extremos mas notables de esta forma de probar algoritmos de clasificación. También, presenta un parámetro conocido como área bajo la curva (llamado AUC, por sus siglas en inglés) que, como su nombre lo dice, mide el área bidimensional bajo la curva ROC de un modelo al hacer variar el punto de decisión en un rango entre 0 y 1 y graficar el porcentaje de aciertos que se obtienen en la clasificación en un rango de 0 a 1, obteniéndose una gráfica con área bajo la curva máxima de 1. Al analizar el área bajo la curva se observa que un modelo con un área bajo la curva $AUC = 1$ es capaz de clasificar correctamente cualquier entrada sin importar el punto de decisión elegido para el modelo. Obtener un modelo completamente perfecto es raro, generalmente solamente sucede con una muestra de datos muy sencilla y fácil de clasificar.

Un área bajo la curva $AUC = 0.5$ se dice que no tiene capacidad de clasificar ya que es equivalente a clasificar completamente al azar con una probabilidad del 50% de estar en lo correcto para cada caso.

Es importante probar las curvas ROC de un modelo contra un punto de referencia establecido para saber si un modelo tiene una capacidad de clasificación relativamente alta o baja en comparación a los algoritmos o modelos ya existentes.




FIGURA 6.1: Izquierda: gráfico ROC con capacidad de clasificación perfecta. Centro: Ejemplo de curva ROC de un modelo cualquiera. Derecha: Gráficos ROC sin capacidad de clasificación.

6.2. Matriz de confusión

La matriz de confusión es otra herramienta utilizada para la evaluación de los modelos de clasificación. La Figura 6.2 muestra un ejemplo de una matriz de confusión y sus partes para un modelo de clasificación en el cual se busca distinguir entre dos categorías. Como se puede observar esta consiste en un arreglo cuadrado de valores comenzando por un arreglo de 2x2 en el cual se organizan los 4 casos posibles del modelo para una predicción. En la diagonal principal están los verdaderos positivos y los verdaderos negativos lo que significa que el modelo realizó su predicción correctamente. Fuera de la diagonal principal se encuentran los valores en los cuales el modelo comete un error de clasificación, ya sea un error de falso positivo o un error de falso negativo.

Verdadero Positivo	Falso Positivo
Falso Negativo	Verdadero Negativo

FIGURA 6.2: Organización de los datos en la matriz de confusión.

Capítulo 7

Estrategia de análisis

7.1. Muestra de datos simulados.

Los datos utilizados en este estudio se encuentran disponibles públicamente mediante la iniciativa CERN opendata [18]. El CERN opendata pone a disposición del público grandes cantidades de datos (cerca de 5 Petabytes) para su estudio independiente y libre [19]. La muestra de datos utilizada en este trabajo fue derivada de la simulación mediante mecanismos QCD de colisiones protón-protón a 13 TeV de energía de centro de masa generados con Pythia8 [20]. Estos datos fueron generados mediante una simulación del detector CMS y reconstruidos de dichas señales detectadas utilizando el algoritmo de flujo de partículas PF por sus siglas en inglés, con lo cual se obtienen los candidatos PF. Con los candidatos se realiza el agrupamiento utilizando el algoritmo anti- k_t con un parámetro de distancia o tamaño final del jet $R = 0.4$ como se describe en [19]. Finalmente se realizó una corrección estándar L1+L2+L3+energía de jet residual a los jets. La contaminación de agrupamiento ([jetArea](#)) fue mitigado utilizando el algoritmo de substracción de hadrón cargado (o, CHS por sus siglas en ingles). La muestra de datos completa consiste en 9754240 eventos organizados en 122 archivos en total, de los cuales se seleccionaron, para cada evento de colisión, los jets con momento transversal ([jetPt](#)) mayor a 30 GeV y pseudorapidez menor a 2.5 ([jetEta](#)).

7.2. Análisis de variables reconstruidas

La estrategia de análisis consta de los siguientes pasos

- Estudio de muestras de datos de procesos que contienen jets. Estas muestras son tomadas del repositorio de datos abiertos del CERN (CERN Open Data) y su análisis se hace por medio del programa de análisis de datos ROOT y lenguaje de programación python. El objetivo es la identificación de las variables reconstruidas de los jets que proporcionen una discriminación entre jets provenientes de quarks o gluones. Las variables disponibles en las muestras simuladas se discuten en la sección 7.3.
- Estudio y entrenamiento de un modelo en redes neuronales usando una arquitectura propuesta en el mismo repositorio de datos abiertos (modelo original) y recursos computacionales del Centro de Computo de Alto Rendimiento de la Universidad de Sonora (ACARUS). Dicho modelo se usará como punto de partida para el proceso de optimización. Una descripción del modelo original se discute en detalle en la sección 8.1.
- Estudio de métodos para optimización de modelos de redes neuronales y descripción de indicadores estadísticos para comparación de desempeño, como lo son las curvas ROC y matrices de confusión, lo cual se discute a detalle en la sección 8.2.

7.3. Variables reconstruidas

A continuación se listan algunas de las variables reconstruidas que proporcionan información de la dinámica de los jets y sus partículas constituyentes. Se espera que estas variables proporcionen información relevante para la separación de jets provenientes de quarks o gluones.

- Momento Lineal Radial jetGirth (grosor). El mejor observable continuo es el momento Lineal Radial, conocido coloquialmente como el grosor o el ancho del jet, que se obtiene sumando los depósitos de momento transversal dentro del jet, promediado por la distancia del eje del jet de la siguiente forma:

$$g = \sum_{i \in \text{jet}} \frac{p_T^i}{p_T^{\text{jet}}} |r_i| \quad (7.1)$$

donde

$$r_i = \sqrt{\Delta y_i^2 + \Delta \phi_i^2} \quad (7.2)$$

en donde y_i es la rapidez invariante del jet masivo.

- jetMass (masa) La masa del jet es calculada utilizando los cuadrimomentos y la energía.

$$M = \sqrt{E^2 - p_T^2 - p_z^2} \quad (7.3)$$

- jetArea (área) (Área de atrapamiento de los jets) El área de un jet se mide como su susceptibilidad a la radiación como el amontonamiento (pileup o PU, por sus siglas en inglés) o el evento subyacente (UE, por sus siglas en inglés). El PU y UE afectan al jet en dos formas: las partículas generadas por las radiaciones se pueden juntar con el jet aumentando su momento transversal o pueden modificar la manera en que las partículas dispersadas se acumulan en jets. Tomando en cuenta ambos efectos, se distribuyen ambos tipos de contaminación por dichas radiaciones sobre los jets y la magnitud de efecto que tiene sobre el jet se le conoce como el área de captación del jet (catchment area).
- jetEta (pseudorapidez del jet) La pseudorapidez denotada por η es la coordenada que describe el ángulo entre el jet de un evento con respecto al eje perpendicular al haz

$$\eta = -\ln\left[\tan\left(\frac{\theta}{2}\right)\right] \quad (7.4)$$

donde θ es el ángulo que forma el jet con respecto al eje paralelo al haz, como se muestra en la Figura 7.1.

- jetPt (momento transversal) El momento transversal denominado p_T como se muestra en la Figura 7.1 está definida como la proyección del momento total del jet sobre el plano xy perpendicular al haz de partículas.

$$p_T = p \sin(\theta)$$

- jetPhi (ángulo ϕ) Como se observa en la Figura 7.1 el ángulo ϕ también conocido como ángulo azimutal está definido como el ángulo entre el momento transversal y el eje y.
- QGaxis2 (eje menor) Al aproximar un jet como un elipse, se toma el valor de su eje menor. Se espera que los jets gluones tengan un valor de eje menor, haciendo el jet más angosto.
- QGmult (Multiplicidad) La multiplicidad está definida como el número total de candidatos que fueron utilizados para la reconstrucción del jet. Se espera que en promedio los jets provenientes de quarks tengan valores de multiplicidad menores que los jets provenientes de gluones.
- QGptD (Momento transversal quark-gluón) La variable $p_T D$ esta definida como la función fragmentación que calcula la energía que acarrea cada constituyente del jet como se observa

en la siguiente formula:

$$p_{TD} = \frac{\sqrt{\sum_i p_{T,i}^2}}{\sum_i p_{T,i}} \quad (7.5)$$

Se espera que en promedio los jets generados por quarks tengan mayor fragmentación, lo que significa que tiene más energía en menos constituyentes.

- alfa (ángulo alfa) En un evento de 3 jets como el de la Figura 7.2, el valor de alfa está definido por la razón entre el momento transversal del tercer jet y el momento transversal promedio de los otros dos jets, también conocidos como los jets principales.
- nGenJetPF (número de partículas en el jet generador) Número de partículas en el jet al nivel del generador.




FIGURA 7.1: Ángulos medidos con respecto al jet en el experimento CMS. El eje z está definido por donde pasa el haz de partículas, el eje x está definido hacia la parte superior del detector y el eje y apunta hacia el costado del detector. (Imagen obtenida de [21]).










FIGURA 7.2: Evento de 3 jets a 7.2 TeV mostrando los jets en amarillo. (Imagen obtenida de [22]).

Las gráficas de las variables que se utilizaron para el entrenamiento de la red neuronal fueron seleccionadas de las 66 variables originales, de donde 11 sobresalieron por su capacidad para discriminar entre jets provenientes de interacción de quarks de los provenientes de gluones. Los histogramas se presentan en las Figuras 7.3 a 7.13. Los histogramas en rojo están compuestos por jets provenientes de quarks y sobrepuesto el histograma en azul jets de gluones:

FIGURA 7.3: Distribuciones de la variable `jetGirth`.FIGURA 7.4: Distribuciones de la variable `jetMass`.FIGURA 7.5: Distribuciones de la variable `jetArea`.

FIGURA 7.6: Distribuciones de la variable jetEta .FIGURA 7.7: Distribuciones de la variable jetPt .FIGURA 7.8: Distribuciones de la variable JetPhi .




FIGURA 7.9: Distribuciones de la variable Qaxis2.




FIGURA 7.10: Distribuciones de la variable QGmult.






FIGURA 7.11: Distribuciones de la variable QGptD.

FIGURA 7.12: Distribuciones de la variable α .FIGURA 7.13: Distribuciones de la variable $nGenJetPF$.

7.4. Matriz de correlaciones de variables reconstruidas.

En la Figura 7.14 se presentan los valores de los coeficientes de correlación de las variables seleccionadas para la identificación de jets provenientes de quarks y gluones. En el sistema de colores la casilla se presenta mas roja si tiene un coeficiente cercano a 1 o azul si se presenta un coeficiente cercano a 0.

Para el análisis realizado en el presente trabajo se busca menor correlación para que las variables tengan una mejor capacidad de clasificación.




FIGURA 7.14: Matriz de los coeficientes de correlación entre las variables seleccionadas.

7.5. Entrenamiento de la red neuronal de clasificación.

El entrenamiento de la red neuronal se realizó por el método de clasificación supervisada en la que se presenta una base de datos que busca predecir el valor de una variable binaria utilizando múltiples variables adicionales ligadas a un evento, en este caso se pregunta si un jet proviene de interacciones de gluones o quarks. En el experimento CMS se almacenan 66 variables por evento de las cuales fueron seleccionadas las 11 que presentan una diferencia entre jets producidos por quarks y jets producidos por gluones.

Para cada paso del entrenamiento se realizaron 2 entrenamientos del modelo con 20 iteraciones

cada uno, se definió una función de terminación temprana del proceso con un valor de paciencia de 3, lo cual significa que al tener 3 iteraciones en las cuales no se presenta una reducción en la pérdida del entrenamiento este se interrumpe antes de las 20 iteraciones y se guarda para continuar al siguiente.

Se entrenó el modelo utilizando tandas de 128 datos a la vez y los datos se separaron en 80 % de datos de entrenamiento y 20 % de datos de prueba.

La búsqueda del modelo óptimo se realizó con un rango definido de variables que se probaron, una a la vez, para encontrar el mejor modelo, pero todas entran en la misma estructura general en la Tabla 7.1

Capa densa, activación ReLu, entre 0 y 512 unidades
Capa dropout, 0.2 de parámetro
Capas densas entre 2-6, activación ReLu, entre 0 y 512 unidades
Capa sigmoide
Tasa de aprendizaje entre 0.01 y 0.0001

TABLA 7.1: Estructura general modelos generados. Capa densa o completamente conectada indica que las neuronas de esa capa tienen acceso a cada uno de los neuronas de la capa anterior y de la capa siguiente.

Capítulo 8

Resultados

8.1. Modelo de red neuronal original

La red neuronal original contra la que se comparan los resultados de la optimización se representa en la Figura [8.1](#)

Tipo de Capa	Número de Activaciones	Número de parámetros
Dense	100	600
Dropout	0.2	0
Dense	100	10100
Dropout	0.2	0
Dense	50	5050
Sigmoid	1	51
Número total de parámetros: 15801		

TABLA 8.1: Estructura del modelo original.

Partiendo de este modelo original que utiliza las siguientes variables para su entrenamiento:

1. Momento transversal
2. Pseudo-rapidez
3. Multiplicidad del jet
4. Momento transversal quark gluon
5. Eje menor

se compara con el clasificador de jets provenientes de quarks y gluones para medir su capacidad de identificar si un jet en la muestra de datos fue generado por interacciones de quarks o gluones




FIGURA 8.1: Comparación de curvas ROC de la red neuronal original (azul) y clasificador de jets (rojo).

como se muestra en la Figura 8.1. Se observa una diferencia del 0.05 en el área bajo la curva, una mejoría de alrededor del 5 %

8.2. Optimización de red neuronal

La optimización de la red se ha realizado con dos formas de 100 variaciones por cada método, sobre los parámetros de la red neuronal; los parámetros que fueron variados son:

1. Número de capas.
2. Número de nodos por capa.
3. Porcentaje de nodos desactivados por capa dropout.
4. Taza de aprendizaje.

Después de las 100 iteraciones se guarda el mejor modelo de cada método de optimización como siguen:

Modelo optimizado por búsqueda en red:

Tipo de Capa	Número de Activaciones	Número de parámetros
Dense	32	384
Dropout	0.2	0
Dense	128	4224
Dense	128	16512
Sigmoid	1	129
Número total de parámetros: 21249		

TABLA 8.2: Modelo de búsqueda en red obtenido tras 100 iteraciones con 20 pruebas por iteración.

Modelo optimizado por búsqueda aleatoria:

Tipo de Capa	Número de Activaciones	Número de parámetros
Dense	128	1536
Dropout	0.2	0
Dense	64	8256
Dense	128	8320
Dense	32	4128
Sigmoid	1	33
Número total de parámetros: 22273		

TABLA 8.3: Modelo de búsqueda aleatoria obtenido tras 100 iteraciones con 20 pruebas por iteración.

Las Figuras 8.2, 8.3, 8.4, muestran la ganancia de la exactitud a lo largo de las iteraciones para las muestras de entrenamiento y prueba. La exactitud es definida como la razón entre la cantidad de clasificaciones correctas y el número de muestras en total. La exactitud es una variable que va de 0 a 1, en donde 0 indica que no hay ninguna predicción correcta y 1 indica que todas las predicciones han sido correctas.

Se utilizaron los métodos de curva ROC en la Figura 8.5 así como las matrices de confusión de las Figuras: 8.9, 8.7, 8.8 y 8.6 para realizar la comparación de los 4 modelos y se pueden observar los resultados a continuación.




FIGURA 8.2: Curva de exactitud del modelo original.




FIGURA 8.3: Curva de exactitud modelo del búsqueda en red.




FIGURA 8.4: Curva de exactitud del modelo búsqueda aleatoria.




FIGURA 8.5: Comparación de curvas ROC para el clasificador de jets provenientes de quarks y gluones, red neuronal original, modelo obtenido por búsqueda aleatoria y modelo obtenido por búsqueda en red.

Matriz de confusión clasificador de jets provenientes de quarks o gluones




FIGURA 8.6: Matriz de confusión para clasificador de jets provenientes de quarks y gluones.




FIGURA 8.7: Matriz de confusión para el modelo neuronal original.




FIGURA 8.8: Matriz de confusión para el mejor modelo obtenido por medio de búsqueda aleatoria.




FIGURA 8.9: Matriz de confusión para el mejor modelo obtenido por medio de búsqueda en red.

Conclusiones

En este trabajo se presenta el desarrollo y optimización de una red neuronal con el fin de clasificar jets de hadrones identificando su origen entre quarks y gluones, buscando aumentar su eficacia y disminuir su tasa de errores. Utilizando dos métodos de búsqueda de los hiperparámetros óptimos de las redes neuronales y realizando la comparación de las curvas ROC y las Matrices de confusión y, comparando la eficacia de todos los modelos, se observa que el modelo óptimo encontrado fue el de la búsqueda aleatoria con estructura en la Tabla 8.3, el cual presentó una área bajo la curva ROC cerca de 0.86 y matriz de confusión mostrada en la Tabla 8.8 en la cual el modelo clasificó correctamente alrededor del 75 % de los jets.

Ambos modelos neuronales obtenidos por la búsqueda aleatoria y en red presentan entre sí una diferencia menor al 1 % en área bajo la curva ROC, así como en positivos y negativos verdaderos de sus matrices de confusión. En comparación con el modelo neuronal original creado sin método de optimización de hiperparámetros, nuestro modelo presenta una mejoría de alrededor del 3 %, mientras que en comparación con el clasificador de jets provenientes de quarks o gluones que fue tomado como punto de referencia inicial para la identificación, se presentó una mejoría de alrededor del 8 %.

Perspectivas a futuro

En el presente trabajo se han detectado las limitaciones del modelo implementado para la clasificación de jets de acorde a sus mecanismos de origen, tomando una perspectiva optimista se esperaría llegar a una mayor eficacia en el futuro, a continuación se indican tres maneras de abordar dicho problema buscando mejorar los métodos para la clasificación de jets en el futuro.

1. Realizar una búsqueda exhaustiva de estructuras de modelos de red neuronal, iterando sobre un rango mas amplio buscando una solución que obtenga una mejor capacidad de clasificación.
2. Obtener una muestra de datos mas extensa o bien buscando nuevas variables que las actualmente utilizadas y que tengan mayor capacidad de clasificación.
3. Aprovechar las propiedades físicas del sistema para buscar la forma de orientar al modelo, agregándole información y orientándolo para llegar a una mayor capacidad de clasificación.
4. Implementar una arquitectura distinta a la red neuronal, dada la naturaleza de los detectores y su forma de almacenar imágenes de datos a través del tiempo se podría intentar con un modelo convolución el cual puede observar los datos como una imagen completa de datos a través del tiempo y encontrar patrones de esa forma.

Apéndice A

Apéndice

A.1. Clasificador de probabilidad de gluones y quarks.

El clasificador de jets provenientes de quarks o gluones [23] es un clasificador de jets que busca identificar si un jet de hadrones reconstruido es proveniente de quarks o de gluones. Se basa en algunas observaciones sobre los distintos tipos de jets que incluyen una mayor multiplicidad en los jets de gluones que en los jets de quarks livianos, así como en la diferencia en las formas y distribución de energías de los constituyentes de los jets, donde se espera que los jets provenientes de quarks sean mas angostos y con una menor distribución de energía en sus constituyentes.

Es por las observaciones ya mencionadas que las únicas tres variables que se toman en cuenta para el clasificador son: las multiplicidades ([QGmult](#)), la forma de los jets ([QGaxis2](#)) y la función de fragmentación de los jets ([QGptD](#)). El clasificador de jets provenientes de quarks y gluones se basa en la función de densidad de probabilidad (o PDF, por sus siglas en inglés) para calcular la probabilidad de que, dadas las tres variables mencionadas anteriormente para un jet cualquiera, el clasificador obtenga una probabilidad entre cero y uno, donde cero indica que el jet es proveniente de gluones y uno indica que el jet es proveniente de quarks. Este modelo es el que se quiere comparar con un modelo alternativo en base a redes neuronales y contrastar el desempeño de ambos.

Bibliográfia

- [1] R. N. Cahn and J. F. Gunion, “Gluon jet production by the process $e^+e^- \rightarrow e^+e^- + \text{gluon-gluon}$,” *Phys. Rev. D*, vol. 20, pp. 2253–2261, Nov 1979. [1](#)
- [2] A. A. Pol, T. Aarrestad, E. Govorkova, R. Halily, A. Klempner, T. Kopetz, V. Loncar, J. Ngadiuba, M. Pierini, O. Sirkin, and S. Summers, “Lightweight jet reconstruction and identification as an object detection task,” *Machine Learning: Science and Technology*, vol. 3, p. 025016, jul 2022. [2](#)
- [3] “Buckminsterfullerene C60.” <https://commons.wikimedia.org/wiki/File:Buckminsterfullerene.png>. CC BY-SA 3.0. [4](#)
- [4] P. Mulders *Quantum Field theory*, Oct 2008. [5](#)
- [5] M. Riordan, “The discovery of quarks,” *Science*, vol. 256, no. 5061, pp. 1287–1293, 1992. [5](#)
- [6] J. Ellis, “The discovery of the gluon,” *International Journal of Modern Physics A*, vol. 29, p. 1430072, Dec. 2014. [6](#)
- [7] P. Wang, “Color confinement, dark matter and the missing anti-matter,” *Journal of Physics G: Nuclear and Particle Physics*, vol. 48, p. 105002, Sept. 2021. [7](#)
- [8] C. Collaboration, “Observation of enhanced long-range elliptic anisotropies inside high-multiplicity jets in pp collisions at $\sqrt{s} = 13$ tev,” 2023. [7](#)
- [9] O. Brüning, H. Burkhardt, and S. Myers, “The large hadron collider,” *Progress in Particle and Nuclear Physics*, vol. 67, no. 3, pp. 705–734, 2012. [8](#)
- [10] S. S. Ghosh and on behalf of the CMS Collaboration, “Highlights from the compact muon solenoid (cms) experiment,” *Universe*, vol. 5, no. 1, 2019. [9](#)
- [11] C. Collaboration, “What is cms?.” <https://cms.cern/news/what-cms>, 2024. Accessed: 2024-05-23. [10](#)
- [12] A. M. e. a. Sirunyan, “Calibration of the cms hadron calorimeters using proton-proton collision data at $s = 13$ tev,” *Journal of Instrumentation*, vol. 15, 5 2020. [10](#), [11](#)
- [13] S. Abdullin, V. Abramov, B. Acharya, N. Adam, M. Adams, P. Adzic, N. Akchurin, U. Akgun, E. Albayrak, R. Alemany-Fernandez, N. Almeida, G. Anagnostou, D. Andelin, E. Anderson, M. Anfreville, I. Anicin, G. Antchev, Z. Antunovic, and R. Arcidiacono, “Erratum : The cms barrel calorimeter response to particle beams from 2 to 350 gev/c,” *The European Physical Journal C*, vol. 60, 04 2009. [10](#), [11](#)
- [14] A. Zghiche and on behalf of the CMS Collaboration, “Performance of the cms electromagnetic calorimeter during the lhc run ii,” *Journal of Physics: Conference Series*, vol. 1162, p. 012001, jan 2019. [10](#)

-
- [15] R. Atkin, “Review of jet reconstruction algorithms,” *Journal of Physics: Conference Series*, vol. 645, p. 012008, sep 2015. [12](#), [13](#)
 - [16] B. Schlag, “Jet Reconstruction in the ATLAS Level-1 Calorimeter Trigger with Deep Artificial Neural Networks,” 2018. Presented 20 Aug 2018. [12](#)
 - [17] M. Cacciari, G. P. Salam, and G. Soyez, “The anti-ktjet clustering algorithm,” *Journal of High Energy Physics*, vol. 2008, p. 063–063, Apr. 2008. [12](#)
 - [18] O. at CERN *Open Data — OpenScience at CERN*. [27](#)
 - [19] K. Kallonen, “Sample with jet properties for jet-flavor and other jet-related ml studies,” 2019. [27](#)
 - [20] CMS Collaboration, “Simulated dataset QCD_Pt-15to7000_TuneCUETP8M1_Flat_13TeV_pythia8 in MINIAODSIM format for 2016 collision data,” 2019. CERN Open Data Portal. [27](#)
 - [21] F. R. Villatoro, “Dibujo20160516 pseudorapidity eta calorimeters cms lhc cern,” *La Ciencia de la Mula Francis*, May 2016. [30](#)
 - [22] CMS Collaboration, “Three is a charm!,” *CMS Experiment*, July 2023. [31](#)
 - [23] “Performance of quark/gluon discrimination in 8 TeV pp data,” tech. rep., CERN, Geneva, 2013. [47](#)